




МАТЕМАТИЧЕСКАЯ СТАТИСТИКА

ВОПРОСЫ К ЭКЗАМЕНУ

Савин Владимир Юрьевич

[Telegram](#)

RANEPА 2026

Содержание

1 Коллоквиум №2	3
1.0.1 Статистическая гипотеза. Процедура проверки нулевой гипотезы	3
1.0.2 Конкурирующая гипотеза. Ошибка первого и второго рода	3
1.0.3 Уровень значимости критерия. Статистический критерий	3
1.0.4 Наблюдаемое значение критерия. Критическая область. Область принятия гипотезы. Критические точки	3
1.0.5 Правосторонняя, левосторонняя и двусторонняя критическая область	3
1.0.6 Основной принцип и этапы проверки гипотез	4
1.0.7 Проверка гипотезы о вероятности события	4
1.0.8 Проверка гипотезы о математическом ожидании при известной генеральной дисперсии	4
1.0.9 Проверка гипотезы о математическом ожидании при неизвестной генеральной дисперсии	4
1.0.10 Сравнение двух математических ожиданий при известных генеральных дисперсиях	4
1.0.11 Сравнение двух математических ожиданий при неизвестных генеральных дисперсиях	5
1.0.12 Сравнение двух дисперсий	5
1.0.13 Однофакторный дисперсионный анализ (главная идея, источники дисперсии)	5
1.0.14 Таблица однофакторного дисперсионного анализа	5
1.0.15 Проверка гипотезы о виде закона распределения. Критерий Пирсона	6
1.0.16 Проверка гипотезы о равномерном распределении	6
1.0.17 Проверка гипотезы о биномиальном распределении	6
1.0.18 Проверка гипотезы о распределении Пуассона	6
1.0.19 Проверка гипотезы о нормальном распределении	6
1.0.20 Проверка гипотезы об однородности выборок: критерий Колмогорова-Смирнова	6
1.0.21 Проверка гипотезы об однородности выборок: критерий «хи-квадрат»	6
1.0.22 Проверка гипотезы об однородности выборок: критерий Вилкоксона-Манна-Уитни	7
1.0.23 Функциональная, статистическая и корреляционная зависимость	7
1.0.24 Метод наименьших квадратов. Необходимое условие экстремума. Система для определения параметров регрессии	7
1.0.25 Общий вид уравнения регрессии Y по X . Выборочный коэффициент регрессии	7
1.0.26 Общий вид уравнения регрессии X по Y . Выборочный коэффициент регрессии	8
1.0.27 Выборочный коэффициент корреляции (формула, значение, симметричность)	8
1.0.28 Связь между коэффициентом корреляции и коэффициентами регрессии	8
1.0.29 Свойства коэффициента корреляции	8
1.0.30 Проверка значимости коэффициента корреляции	8
1.0.31 Эмпирическое корреляционное отношение (формулы, значение, свойства). Эмпирический коэффициент детерминации	8
1.0.32 Индекс корреляции (формулы, значение). Коэффициент детерминации	9
1.0.33 Проверка линейности корреляционной зависимости	9
1.0.34 Проверка значимости эмпирического корреляционного отношения	9
1.0.35 Проверка значимости индекса корреляции	9
1.0.36 Корреляционная матрица	9
1.0.37 Множественный коэффициент корреляции (значение, общая формула, случай трёх переменных)	9
1.0.38 Свойства множественного коэффициента корреляции. Множественный коэффициент детерминации. Проверка значимости	10
1.0.39 Частный коэффициент корреляции (формула, свойства)	10
1.0.40 Проверка значимости частного коэффициента корреляции	10
1.0.41 Ранговая корреляция: коэффициент Спирмена (расчёт, проверка значимости)	10
1.0.42 Ранговая корреляция: коэффициент Кендалла (расчёт, проверка значимости)	11

1 Коллоквиум №2

1.0.1 Статистическая гипотеза. Процедура проверки нулевой гипотезы

Определение 1. *Статистическая гипотеза* – это предположение о виде неизвестного распределения или о параметрах известных распределений.

Выдвинутую гипотезу называют **нулевой (основной)** и обозначают H_0 .

Процедура проверки нулевой гипотезы заключается в установлении критических пределов для оценки значимых отклонений вычисленной статистики θ^* от гипотетического значения параметра θ . Для этого используют специально подобранную случайную величину K (статистический критерий), распределение которой известно при условии H_0 . По выборочным данным вычисляют наблюдаемое значение $K_{\text{набл}}$ и сравнивают его с критическим $k_{\text{кр}}$, найденным по уровню значимости α . Если $K_{\text{набл}}$ попадает в критическую область, H_0 отвергают; в противном случае – принимают.

1.0.2 Конкурирующая гипотеза. Ошибка первого и второго рода

Определение 2. *Конкурирующей (альтернативной)* называют гипотезу H_1 , которая противоречит нулевой.

При проверке гипотез возможны ошибки:

- **Ошибка первого рода** – отвергнуть H_0 , когда она верна. Её вероятность α называют уровнем значимости.
- **Ошибка второго рода** – принять H_0 , когда она неверна. Её вероятность обозначают β .

Мощность критерия – вероятность $1 - \beta$ отвергнуть неверную H_0 . Хороший критерий имеет малые α и β .

1.0.3 Уровень значимости критерия. Статистический критерий

Определение 3. *Уровень значимости α* – вероятность ошибки первого рода. Наиболее часто используют $\alpha = 0,10; 0,05; 0,01$.

Определение 4. *Статистический критерий K* – случайная величина, распределение которой при справедливости H_0 известно. По её значению принимают решение о принятии или отклонении H_0 .

1.0.4 Наблюдаемое значение критерия. Критическая область. Область принятия гипотезы. Критические точки

Определение 5. *Наблюдаемое (фактическое) значение $K_{\text{набл}}$* – значение критерия, вычисленное по выборочным данным.

Определение 6. *Критическая область* – множество значений критерия, при которых H_0 отвергают. Область принятия – дополнение критической области.

Определение 7. *Критические точки (границы) $k_{\text{кр}}$* – значения, отделяющие критическую область от области принятия. Их находят из условия $P(K \in \text{крит. обл.} \mid H_0) = \alpha$.

1.0.5 Правосторонняя, левосторонняя и двусторонняя критическая область

В зависимости от альтернативной гипотезы H_1 выбирают вид критической области:

- **Правосторонняя:** $(k_{\text{кр}}; +\infty)$, $P(K > k_{\text{кр}}) = \alpha$. Применяется при $H_1 : \theta > \theta_0$.
- **Левосторонняя:** $(-\infty; k_{\text{кр}})$, $P(K < k_{\text{кр}}) = \alpha$. Применяется при $H_1 : \theta < \theta_0$.
- **Двусторонняя:** $(-\infty; k_1) \cup (k_2; +\infty)$, $P(K < k_1) = \alpha/2$, $P(K > k_2) = \alpha/2$. Применяется при $H_1 : \theta \neq \theta_0$.

1.0.6 Основной принцип и этапы проверки гипотез

Основной принцип: если $K_{\text{набл}} \in \text{крит. обл.} - H_0$ отвергают; если $K_{\text{набл}} \in \text{обл. принятия} - H_0$ принимают.

Этапы проверки гипотез:

1. Сформулировать H_0 и H_1 .
2. Выбрать уровень значимости α и критерий K .
3. По выборке вычислить $K_{\text{набл}}$.
4. По таблицам или с помощью Excel найти $k_{\text{кр}}$.
5. Сравнить и сделать вывод.

1.0.7 Проверка гипотезы о вероятности события

Пусть n – объём выборки, m – число появлений события A , $\omega = m/n$ – выборочная доля. Проверяется $H_0 : p = p_0$. Для больших n ($n \geq 30$) статистика критерия:

$$V_{\text{набл}} = \frac{\omega - p_0}{\sqrt{p_0(1 - p_0)/n}} \sim N(0,1).$$

Критическое значение $v_{\text{кр}}$ находят из функции Лапласа: для двусторонней альтернативы $\Phi(v_{\text{кр}}) = (1 - \alpha)/2$, для односторонней $\Phi(v_{\text{кр}}) = (1 - 2\alpha)/2$. Правило: если $|V_{\text{набл}}| < v_{\text{кр}} - H_0$ принимается; иначе – отвергается (с учётом знака для односторонней альтернативы). Для конечной генеральной совокупности при $n > 0,05N$ в знаменатель добавляется множитель $\sqrt{1 - n/N}$.

1.0.8 Проверка гипотезы о математическом ожидании при известной генеральной дисперсии

Пусть $X \sim N(a, \sigma^2)$, σ^2 известно. Проверяется $H_0 : a = a_0$. Статистика:

$$U_{\text{набл}} = \frac{\bar{x}_B - a_0}{\sigma/\sqrt{n}} \sim N(0,1).$$

Критическое значение $u_{\text{кр}}$ находится по функции Лапласа. Правила принятия H_0 аналогичны предыдущему пункту (с заменой V на U).

1.0.9 Проверка гипотезы о математическом ожидании при неизвестной генеральной дисперсии

Когда σ^2 неизвестна, используют несмещённую оценку $S^2 = \frac{n}{n-1} \sigma_B^2$. Статистика:

$$T_{\text{набл}} = \frac{\bar{x}_B - a_0}{S/\sqrt{n}} \sim t(n-1),$$

где $t(k)$ – распределение Стьюдента с k степенями свободы. Критические значения $t_{\text{кр}}$ берут из таблиц распределения Стьюдента для заданного α и $k = n - 1$ (двустороннего или одностороннего в зависимости от H_1). Правила принятия H_0 те же, что и для известной дисперсии.

1.0.10 Сравнение двух математических ожиданий при известных генеральных дисперсиях

Имеются две независимые выборки из нормальных совокупностей с известными σ_X^2, σ_Y^2 . Проверяется $H_0 : a_X = a_Y$. Статистика:

$$Z_{\text{набл}} = \frac{\bar{x}_B - \bar{y}_B}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \sim N(0,1).$$

Критические значения и правила проверки – как в случае проверки математического ожидания при известной дисперсии (с заменой U на Z).

1.0.11 Сравнение двух математических ожиданий при неизвестных генеральных дисперсиях

Дисперсии неизвестны, используют их оценки S_X^2, S_Y^2 . Статистика:

$$T_{\text{набл}} = \frac{\bar{x}_B - \bar{y}_B}{\sqrt{\frac{S_X^2}{n} + \frac{S_Y^2}{m}}} \sim t(k),$$

где число степеней свободы k определяется по формуле Саттертуэйта:

$$k = \frac{\left(\frac{S_X^2}{n} + \frac{S_Y^2}{m}\right)^2}{\frac{(S_X^2/n)^2}{n-1} + \frac{(S_Y^2/m)^2}{m-1}}.$$

При предположении о равенстве дисперсий $k = n + m - 2$. Критические значения – по распределению Стьюдента.

1.0.12 Сравнение двух дисперсий

По двум независимым выборкам из нормальных совокупностей вычисляют исправленные выборочные дисперсии S_X^2 и S_Y^2 . Проверяется $H_0 : \sigma_X^2 = \sigma_Y^2$. Критерий:

$$F_{\text{набл}} = \frac{S_{\text{больш}}^2}{S_{\text{мал}}^2} \sim F(k_1, k_2),$$

где $k_1 = n_{\text{больш}} - 1$, $k_2 = n_{\text{мал}} - 1$. Критическая область – правосторонняя: $F_{\text{набл}} > F_{\alpha}(k_1, k_2)$. Если $F_{\text{набл}} > F_{\text{кр}}$, H_0 отвергается (дисперсии различны).

1.0.13 Однофакторный дисперсионный анализ (главная идея, источники дисперсии)

Главная идея: если контролируемый фактор влияет на зависимую переменную Y , то групповые средние при разных уровнях фактора должны значимо различаться. Сравнивают факторную (межгрупповую) дисперсию и остаточную (внутригрупповую) дисперсию.

Источники дисперсии (вариации):

- **Факторная дисперсия** – обусловлена действием изучаемого фактора.
- **Остаточная дисперсия** – обусловлена случайными неконтролируемыми факторами.

Общая дисперсия = факторная + остаточная. Если факторная дисперсия значимо превышает остаточную, влияние фактора считается доказанным.

1.0.14 Таблица однофакторного дисперсионного анализа

Обозначения: p – число уровней фактора, q – число наблюдений на каждом уровне (одинаковое), $n = pq$ – общий объём. $\bar{y}_{Ti}$ – средняя в i -й группе, $\bar{y}$ – общая средняя.

$$SST = \sum_{i=1}^p \sum_{j=1}^q (y_{ij} - \bar{y})^2, \quad SSF = q \sum_{i=1}^p (\bar{y}_{Ti} - \bar{y})^2, \quad SSE = SST - SSF.$$

Источник вариации	Сумма квадратов (SS)	Степени свободы (df)	Средний квадрат (MS)	$F_{\text{набл}}$
Фактор	SSF	$p - 1$	$MSF = SSF/(p - 1)$	MSF/MSE
Остаток	SSE	$p(q - 1)$	$MSE = SSE/(p(q - 1))$	
Всего	SST	$pq - 1$	$MST = SST/(pq - 1)$	

Критическое значение $F_{\text{кр}} = F_{\alpha}(p - 1, p(q - 1))$. Если $F_{\text{набл}} > F_{\text{кр}}$, фактор оказывает существенное влияние.

1.0.15 Проверка гипотезы о виде закона распределения. Критерий Пирсона

Критерий χ^2 Пирсона проверяет согласие эмпирического распределения с теоретическим. Вычисляется:

$$\chi_{\text{набл}}^2 = \sum_{i=1}^m \frac{(n_i - n_i^{\text{теор}})^2}{n_i^{\text{теор}}},$$

где n_i – эмпирические частоты, $n_i^{\text{теор}} = n \cdot p_i^{\text{теор}}$ – теоретические частоты, m – число интервалов. Статистика имеет χ^2 -распределение с $L = m - r - 1$ степенями свободы, где r – число параметров теоретического распределения, оценённых по выборке. Если $\chi_{\text{набл}}^2 \leq \chi_{\text{кр}}^2(\alpha; L)$, гипотеза о выбранном законе принимается; в противном случае – отвергается.

1.0.16 Проверка гипотезы о равномерном распределении

Для равномерного закона на отрезке $[a; b]$ теоретическая вероятность попадания в интервал $[x_i; x_{i+1})$ длины h постоянна: $p_i^{\text{теор}} = h/(b-a)$. Параметры a и b оцениваются по выборке: $\hat{a} = x_{(1)}$, $\hat{b} = x_{(n)}$. Число степеней свободы $L = m - 2$. Далее вычисляется $\chi_{\text{набл}}^2$ по общей формуле. При необходимости интервалы объединяют, чтобы $n_i^{\text{теор}} \geq 5$.

1.0.17 Проверка гипотезы о биномиальном распределении

Биномиальный закон: $P(X = x) = C_{\mu}^x p^x (1-p)^{\mu-x}$, где μ – число испытаний (известно). Неизвестный параметр p оценивается как $\hat{p} = \bar{x}_B / \mu$. Теоретические вероятности вычисляют по формуле Бернулли. Степени свободы $L = m - 2$ (оценивается один параметр p). Критерий Пирсона применяют после объединения интервалов с малыми теоретическими частотами.

1.0.18 Проверка гипотезы о распределении Пуассона

Распределение Пуассона: $P(X = x) = \frac{\lambda^x}{x!} e^{-\lambda}$. Параметр λ оценивается как $\hat{\lambda} = \bar{x}_B$. Теоретические вероятности вычисляют по формуле Пуассона. Степени свободы $L = m - 2$ (оценивается один параметр). Критерий применим при $n p_i^{\text{теор}} \geq 5$; иначе интервалы объединяют.

1.0.19 Проверка гипотезы о нормальном распределении

Нормальный закон: параметры $\hat{a} = \bar{x}_B$, $\hat{\sigma} = S$ (исправленное среднее квадратическое отклонение). Для интервального вариационного ряда теоретические вероятности попадания в интервалы:

$$p_i^{\text{теор}} = \Phi\left(\frac{x_{i+1} - \bar{x}_B}{S}\right) - \Phi\left(\frac{x_i - \bar{x}_B}{S}\right),$$

где Φ – функция Лапласа. Крайние интервалы расширяют до $-\infty$ и $+\infty$. Степени свободы $L = m - 3$ (оцениваются два параметра). Вычисляют $\chi_{\text{набл}}^2$ и сравнивают с критическим значением.

1.0.20 Проверка гипотезы об однородности выборок: критерий Колмогорова-Смирнова

Критерий предназначен для проверки $H_0 : F_1(x) = F_2(x)$ (две выборки из одной генеральной совокупности). Статистика:

$$\lambda_{\text{набл}} = \sqrt{\frac{n_1 n_2}{n_1 + n_2}} \cdot \max_x |F_{n_1}(x) - F_{n_2}(x)|,$$

где F_{n_1}, F_{n_2} – эмпирические функции распределения. Критические значения $\lambda_{\text{кр}}$ табулированы: для $\alpha = 0,05$ $\lambda_{\text{кр}} = 1,36$, для $\alpha = 0,01$ $\lambda_{\text{кр}} = 1,63$. Если $\lambda_{\text{набл}} > \lambda_{\text{кр}}$, H_0 отвергается.

1.0.21 Проверка гипотезы об однородности выборок: критерий «хи-квадрат»

Для l независимых выборок, сгруппированных в m интервалов, статистика:

$$\chi_{\text{набл}}^2 = n \left(\sum_{i=1}^m \sum_{j=1}^l \frac{n_{ij}^2}{n_{i*} n_{*j}} - 1 \right),$$

где n_{ij} – частота попадания элементов j -й выборки в i -й интервал, $n_{i*} = \sum_j n_{ij}$, $n_{*j} = \sum_i n_{ij}$, $n = \sum_i n_{i*} = \sum_j n_{*j}$.

При справедливости H_0 статистика имеет χ^2 -распределение с $(l-1)(m-1)$ степенями свободы. Если $\chi^2_{\text{набл}} > \chi^2_{\text{кр}}$, гипотеза об однородности отвергается.

1.0.22 Проверка гипотезы об однородности выборок: критерий Вилкоксона–Манна–Уитни

Ранговый критерий для двух независимых выборок. Объединяют обе выборки, ранжируют наблюдения, находят сумму рангов S_1 элементов первой выборки. Вычисляют:

$$U = S_1 - \frac{n_1(n_1+1)}{2}.$$

Затем используют стандартизованную статистику:

$$t_{\text{набл}} = \frac{U - \frac{n_1 n_2}{2}}{\sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}} \sim N(0,1).$$

Если $|t_{\text{набл}}| > z_{1-\alpha/2}$ (квантиль нормального распределения), H_0 отвергается.

1.0.23 Функциональная, статистическая и корреляционная зависимость

- **Функциональная зависимость:** каждому значению одной переменной соответствует единственное значение другой ($y = f(x)$).
- **Статистическая (стохастическая) зависимость:** каждому значению одной переменной соответствует распределение другой.
- **Корреляционная зависимость:** частный случай статистической, когда функциональная связь существует между значением одной переменной и условным математическим ожиданием другой: $M(Y|X=x) = \varphi(x)$ (уравнение регрессии).

1.0.24 Метод наименьших квадратов. Необходимое условие экстремума. Система для определения параметров регрессии

Метод наименьших квадратов (МНК): неизвестные параметры b_0, b_1 выбираются так, чтобы сумма квадратов отклонений эмпирических групповых средних $\bar{y}_i$ от теоретических $y_{x_i} = b_0 + b_1 x_i$ была минимальной:

$$S(b_0, b_1) = \sum_{i=1}^l (b_0 + b_1 x_i - \bar{y}_i)^2 n_i \rightarrow \min.$$

Необходимое условие экстремума – равенство нулю частных производных:

$$\frac{\partial S}{\partial b_0} = 0, \quad \frac{\partial S}{\partial b_1} = 0.$$

После упрощений получают систему нормальных уравнений:

$$\begin{cases} b_0 n + b_1 \sum x_i n_i = \sum \bar{y}_i n_i, \\ b_0 \sum x_i n_i + b_1 \sum x_i^2 n_i = \sum x_i \bar{y}_i n_i. \end{cases}$$

В терминах средних:

$$\begin{cases} b_0 + b_1 \bar{x} = \bar{y}, \\ b_0 \bar{x} + b_1 \overline{x^2} = \overline{xy}. \end{cases}$$

1.0.25 Общий вид уравнения регрессии Y по X. Выборочный коэффициент регрессии

Уравнение линейной регрессии Y по X: $y_x = b_0 + b_1 x$. Выборочный коэффициент регрессии Y на X:

$$b_{yx} = \frac{\overline{xy} - \bar{x}\bar{y}}{\overline{x^2} - (\bar{x})^2} = \frac{\widehat{\text{cov}}(X, Y)}{\sigma_X^2}.$$

Он показывает, на сколько единиц в среднем изменяется Y при увеличении X на одну единицу.

1.0.26 Общий вид уравнения регрессии X по Y . Выборочный коэффициент регрессии

Уравнение линейной регрессии X по Y : $x_y = c_0 + c_1 y$. Выборочный коэффициент регрессии X на Y :

$$b_{xy} = \frac{\overline{xy} - \bar{x}\bar{y}}{y^2 - (\bar{y})^2} = \frac{\widehat{\text{cov}}(X, Y)}{\sigma_Y^2}.$$

Он показывает, на сколько единиц в среднем изменяется X при увеличении Y на одну единицу.

1.0.27 Выборочный коэффициент корреляции (формула, значение, симметричность)

Выборочный коэффициент корреляции Пирсона:

$$r = \frac{\overline{xy} - \bar{x}\bar{y}}{\sigma_X \sigma_Y} = \frac{\widehat{\text{cov}}(X, Y)}{\sigma_X \sigma_Y}.$$

Он измеряет тесноту *линейной* связи между X и Y . Значения r лежат в отрезке $[-1; 1]$. Формула симметрична: $r_{XY} = r_{YX}$.

1.0.28 Связь между коэффициентом корреляции и коэффициентами регрессии

Из определений следуют соотношения:

$$r = b_{yx} \frac{\sigma_X}{\sigma_Y} = b_{xy} \frac{\sigma_Y}{\sigma_X}, \quad r^2 = b_{yx} \cdot b_{xy}, \quad r = \pm \sqrt{b_{yx} b_{xy}}.$$

Знак r совпадает со знаком коэффициентов регрессии.

1.0.29 Свойства коэффициента корреляции

1. $-1 \leq r \leq 1$.
2. При $r = \pm 1$ между X и Y существует линейная функциональная зависимость.
3. При $r = 0$ линейная корреляционная связь отсутствует (но может существовать нелинейная).
4. Знак r указывает направление связи: $r > 0$ – прямая, $r < 0$ – обратная.
5. Коэффициент корреляции не изменяется при линейных преобразованиях переменных: $r(aX + b, cY + d) = \text{sgn}(ac) \cdot r(X, Y)$.

1.0.30 Проверка значимости коэффициента корреляции

Проверяется $H_0 : \rho = 0$ (генеральный коэффициент равен нулю). Используется статистика:

$$t_{\text{набл}} = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim t(n-2).$$

Если $|t_{\text{набл}}| > t_{\text{кр}}(\alpha; n-2)$, то H_0 отвергается – коэффициент корреляции значимо отличается от нуля, линейная связь существует.

1.0.31 Эмпирическое корреляционное отношение (формулы, значение, свойства). Эмпирический коэффициент детерминации

Эмпирическое корреляционное отношение η_{yx} измеряет тесноту любой (не только линейной) связи между Y и X :

$$\eta_{yx} = \sqrt{\frac{\delta_{iy}^2}{\sigma_y^2}}, \quad \delta_{iy}^2 = \frac{\sum_{i=1}^l (\bar{y}_i - \bar{y})^2 n_i}{n}, \quad \sigma_y^2 = \frac{\sum_{j=1}^m (y_j - \bar{y})^2 n_j}{n}.$$

Свойства: $0 \leq \eta \leq 1$; $\eta = 0$ – связи нет; $\eta = 1$ – функциональная связь; $\eta_{yx} \neq \eta_{xy}$. η^2 – эмпирический коэффициент детерминации – показывает долю вариации Y , объяснённую вариацией X .

1.0.32 Индекс корреляции (формулы, значение). Коэффициент детерминации

Индекс корреляции R_{yx} (теоретическое корреляционное отношение) характеризует рассеяние точек относительно линии регрессии:

$$R_{yx} = \sqrt{1 - \frac{\sigma_{yx}^2}{\sigma_y^2}},$$

где σ_{yx}^2 – остаточная дисперсия относительно линии регрессии y_x . R^2 – **коэффициент детерминации** – доля вариации Y , объяснённая регрессией. Для линейной регрессии $R_{yx} = |r|$.

1.0.33 Проверка линейности корреляционной зависимости

Для проверки линейности сравнивают η^2 и r^2 :

$$F_{\text{набл}} = \frac{(\eta^2 - r^2)(n - m)}{(m - 2)(1 - \eta^2)} \sim F(m - 2, n - m),$$

где m – число интервалов группировки. Если $F_{\text{набл}} \leq F_{\text{кр}}$, зависимость линейна.

1.0.34 Проверка значимости эмпирического корреляционного отношения

Проверяется $H_0 : \eta = 0$. Используется F -статистика:

$$F_{\text{набл}} = \frac{\eta^2(n - m)}{(1 - \eta^2)(m - 1)} \sim F(m - 1, n - m).$$

Если $F_{\text{набл}} > F_{\text{кр}}(\alpha; m - 1; n - m)$, то η значимо отличается от нуля.

1.0.35 Проверка значимости индекса корреляции

Проверяется $H_0 : R = 0$. Статистика:

$$F_{\text{набл}} = \frac{R^2(n - p)}{(1 - R^2)(p - 1)} \sim F(p - 1, n - p),$$

где $p - 1$ – число объясняющих переменных. Если $F_{\text{набл}} > F_{\text{кр}}(\alpha; p - 1; n - p)$, индекс корреляции значим.

1.0.36 Корреляционная матрица

Для p случайных величин $X_1, X_2, \dots, X_p$ корреляционная матрица – симметричная матрица размера $p \times p$, составленная из парных коэффициентов корреляции ρ_{ij} :

$$\mathbf{P} = \begin{pmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{pmatrix}.$$

Её выборочная оценка $\mathbf{R}$ получается заменой ρ_{ij} на выборочные коэффициенты r_{ij} .

1.0.37 Множественный коэффициент корреляции (значение, общая формула, случай трёх переменных)

Множественный коэффициент корреляции $R_{i;12\dots p}$ измеряет тесноту линейной связи одной переменной X_i с совокупностью остальных $p - 1$ переменных. Общая формула:

$$R_{i;12\dots p} = \sqrt{1 - \frac{|\mathbf{R}|}{\mathbf{R}_{ii}}},$$

где $|\mathbf{R}|$ – определитель корреляционной матрицы, $\mathbf{R}_{ii}$ – алгебраическое дополнение элемента $r_{ii} = 1$. Для трёх переменных ($p = 3$):

$$R_{1;23} = \sqrt{\frac{r_{12}^2 + r_{13}^2 - 2r_{12}r_{13}r_{23}}{1 - r_{23}^2}}.$$

1.0.38 Свойства множественного коэффициента корреляции. Множественный коэффициент детерминации. Проверка значимости

Свойства:

- $0 \leq R \leq 1$.
- R не меньше абсолютной величины любого парного коэффициента корреляции с тем же первым индексом.
- R не указывает направление связи.

R^2 – **множественный коэффициент детерминации** – доля вариации X_i , объяснённая вариацией остальных переменных.

Проверка значимости: $H_0 : R = 0$. Статистика:

$$F_{\text{набл}} = \frac{R^2(n-p)}{(1-R^2)(p-1)} \sim F(p-1, n-p).$$

Если $F_{\text{набл}} > F_{\text{кр}}(\alpha; p-1; n-p)$, то R значимо отличается от нуля.

1.0.39 Частный коэффициент корреляции (формула, свойства)

Частный коэффициент корреляции $r_{ij(12\dots p)}$ измеряет тесноту линейной связи между X_i и X_j после исключения влияния всех остальных переменных. Вычисляется через алгебраические дополнения корреляционной матрицы:

$$r_{ij(12\dots p)} = \frac{-\mathbf{R}_{ij}}{\sqrt{\mathbf{R}_{ii}\mathbf{R}_{jj}}},$$

где $\mathbf{R}_{ij}$ – алгебраическое дополнение элемента r_{ij} . Для трёх переменных:

$$r_{12(3)} = \frac{r_{12} - r_{13}r_{23}}{\sqrt{(1-r_{13}^2)(1-r_{23}^2)}}.$$

Свойства: принимает значения от -1 до 1 ; распределение при $H_0 : \rho = 0$ совпадает с распределением парного коэффициента, но с числом степеней свободы $n - (p - 2)$.

1.0.40 Проверка значимости частного коэффициента корреляции

Проверка гипотезы $H_0 : \rho_{ij(12\dots p)} = 0$ выполняется с помощью статистики:

$$t_{\text{набл}} = \frac{r_{ij(12\dots p)}\sqrt{n-p}}{\sqrt{1-r_{ij(12\dots p)}^2}} \sim t(n-p).$$

Если $|t_{\text{набл}}| > t_{\text{кр}}(\alpha; n-p)$, то частный коэффициент корреляции значим.

1.0.41 Ранговая корреляция: коэффициент Спирмена (расчёт, проверка значимости)

Коэффициент ранговой корреляции Спирмена вычисляется по формуле:

$$\rho_B = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n^3 - n},$$

где $d_i = x_i - y_i$ – разность рангов одного и того же объекта по двум признакам. $\rho_B \in [-1; 1]$.

Расчёт:

1. Присвоить ранги значениям каждого признака (по убыванию или возрастанию).
2. Найти разности рангов d_i .
3. Вычислить $\sum d_i^2$ и подставить в формулу.

Проверка значимости: $H_0 : \rho_B = 0$. Используют статистику:

$$t_{\text{набл}} = \rho_B \sqrt{\frac{n-2}{1-\rho_B^2}} \sim t(n-2).$$

Если $|t_{\text{набл}}| > t_{\text{кр}}(\alpha; n-2)$, коэффициент значим.

1.0.42 Ранговая корреляция: коэффициент Кендалла (расчёт, проверка значимости)

Коэффициент Кендалла τ_B основан на подсчёте числа инверсий.

Расчёт:

1. Упорядочить объекты по одному признаку (ранги x_i становятся $1, 2, \dots, n$).
2. Для последовательности рангов $y_1, y_2, \dots, y_n$ подсчитать для каждого y_i число R_i последующих рангов, больших y_i .
3. Найти сумму $R = \sum_{i=1}^{n-1} R_i$.
4. $\tau_B = \frac{4R}{n(n-1)} - 1$.

Проверка значимости: $H_0 : \tau_\Gamma = 0$. Статистика:

$$z = \frac{3\tau_B \sqrt{n(n-1)}}{\sqrt{2(2n+5)}} \sim N(0,1).$$

Если $|z| > z_{1-\alpha/2}$, то коэффициент Кендалла значим.